

PREVISÃO DO VALOR DE IMÓVEIS COM SUPPORT VECTOR REGRESSION (SVR)

Relatório do trabalho de SVM para regressão com o conjunto de dados California Housing

Nome: João Vitor Ferreira Pedroso

RGM: 11241103647

Curso: Engenharia de Software, Universidade de Mogi das Cruzes (UMC)

Disciplina: Inteligência Artificial

1 INTRODUÇÃO

Estimar o valor de um imóvel a partir de suas características é um problema de regressão supervisionada. O *Support Vector Machine* (SVM) é um algoritmo que ajusta o modelo usando apenas os pontos mais relevantes dos dados de treino, os vetores de suporte, e o *Support Vector Regression* (SVR) é a sua versão para regressão: ele ajusta uma função que tolera erros de até *epsilon* e penaliza os desvios maiores, controlados pelo parâmetro *C*. Como se baseia em distâncias entre pontos, o SVR é sensível à escala das variáveis.

O objetivo deste trabalho é prever o valor mediano de casas com a base *California Housing*, obtendo **R² superior a 0,65** no conjunto de teste, com tratamento justificado de valores ausentes e de outliers.

2 BANCO DE DADOS

Foi utilizada a base *Housing* (California Housing), do Kaggle, com **20.640 registros** e **10 atributos**. Cada registro representa um bloco residencial. Nove atributos são numéricos (*float64*) e um é categórico (*object*). A **variável alvo** é *median_house_value*, o valor mediano das casas do bloco, em dólares.

Tabela 1. Atributos da base de dados

Atributo	Tipo	Descrição
longitude, latitude	float	Posição geográfica do bloco
housing_median_age	float	Idade mediana das casas do bloco
total_rooms, total_bedrooms	float	Total de cômodos e de quartos no bloco
population, households	float	População e quantidade de domicílios do bloco
median_income	float	Renda mediana, em dezenas de milhares de dólares
ocean_proximity	object	Proximidade do oceano (categórico)
median_house_value	float	Variável alvo, valor mediano das casas, em dólares

A análise exploratória mostrou quatro pontos que orientaram o restante do trabalho:

- **Escalas muito diferentes.** *total_rooms* chega a 39.320, enquanto *median_income* varia entre 0,5 e 15. Por isso a padronização é obrigatória no SVR.
- **Teto no alvo.** O valor máximo é 500.001 e se repete em 965 registros, o que indica um limite da coleta. A média (206.855,82) fica acima da mediana (179.700), com assimetria de 0,98.
- **Uma variável domina a correlação.** *median_income* tem correlação de 0,69 com o alvo, e todas as demais ficam abaixo de 0,15 em valor absoluto.
- **Valores ausentes e duplicados.** Apenas *total_bedrooms* tem valores ausentes (207, ou 1,0% da base), e não há registros duplicados.

3 METODOLOGIA

3.1 Valores ausentes e variáveis categóricas

Os 207 valores ausentes de *total_bedrooms* foram imputados pela **mediana** (435), preferida à média (537,87) porque a variável tem cauda longa à direita. Quatro estratégias foram comparadas sob as mesmas condições (Tabela 2) e as diferenças ficaram abaixo de 0,01 de R^2 , de modo que a escolha tem pouco efeito. A mediana foi mantida por preservar todos os registros e todas as colunas. A remoção das linhas obteve o maior R^2 , mas usa uma base com 207 registros a menos, o que altera a divisão treino e teste e impede a comparação direta.

Tabela 2. Estratégias para os valores ausentes

Estratégia	Registros	Colunas	R^2
Remover linhas incompletas	20.433	10	0,7550
Remover a coluna <i>total_bedrooms</i>	20.640	9	0,7506
Imputar pela média	20.640	10	0,7459
Imputar pela mediana (adotada)	20.640	10	0,7487

A variável categórica *ocean_proximity* foi convertida por codificação *one-hot* (*pd.get_dummies*, descartando a primeira categoria), o que resultou em 12 atributos de entrada.

3.2 Análise dos outliers

Os outliers foram identificados pelo método do intervalo interquartil (IQR): é atípico o valor abaixo de $Q1 - 1,5 \times IQR$ ou acima de $Q3 + 1,5 \times IQR$. A identificação foi feita antes de qualquer tratamento (Tabela 3).

Tabela 3. Outliers identificados pelo método do IQR

Variável	Qtd.	%	Mínimo	Máximo
longitude	0	0,00	-124,35	-114,31
latitude	0	0,00	32,54	41,95
housing_median_age	0	0,00	1	52
total_rooms	1.287	6,24	2	39.320
total_bedrooms	1.306	6,33	1	6.445
population	1.196	5,79	3	35.682
households	1.220	5,91	1	6.082
median_income	681	3,30	0,4999	15,0001
median_house_value (alvo)	1.071	5,19	14.999	500.001

Decisão. Os extremos das variáveis de contagem e de *median_income* parecem blocos reais de grande porte, e não erros de cadastro. A remoção foi descartada porque eliminaria mais de 5% da base só em cada variável isolada, e foi aplicado o **capping** (*winsorization*) pelos limites do IQR, que limita os valores extremos sem perder registros. Longitude e latitude foram mantidas, por serem coordenadas sem outliers. O alvo também foi mantido: 965 dos 1.071 valores acima do limite são o teto de 500.001 da própria coleta, e alterar o alvo distorceria a grandeza prevista. **Nenhum registro foi removido.**

3.3 Divisão e padronização

A base foi dividida em 80% para treino (16.512 registros) e 20% para teste (4.128 registros), com *random_state=42*. Os atributos foram padronizados com *StandardScaler*, ajustado somente no treino. O alvo também foi padronizado, com *TransformedTargetRegressor*, que reverte a escala nas previsões, de modo que as métricas continuem em dólares.

Como limitação, a imputação e o capping usaram a base completa antes da divisão, o que é um vazamento leve de informação. O efeito esperado é pequeno, pois afeta 1% dos registros e apenas limita extremos, mas o ideal seria calcular esses valores só no treino.

3.4 Modelo e métricas

O modelo de referência foi o SVR com os parâmetros padrão (kernel *rbf*, $C = 1$, *epsilon* = 0,1, *gamma* = *scale*). Foram comparados os kernels *linear*, *rbf* e *poly*. A avaliação foi feita no conjunto de teste com três métricas: o R^2 , que vale 1 para ajuste perfeito, 0 para um modelo que prevê sempre a média e é negativo quando o modelo é pior que isso; o **MAE**, erro absoluto médio em dólares; e o **RMSE**, que também está em dólares, mas penaliza mais os erros grandes.

3.5 Otimização de hiperparâmetros

Foi usado o *GridSearchCV* com R^2 como métrica e validação cruzada de 3 dobras, testando C em 0,1, 1, 10 e 100, ϵ em 0,01, 0,1 e 0,5, γ em *scale* e *auto*, e kernel *rbf* ou *linear* (48 combinações). Como o custo do SVR cresce rapidamente com o número de registros, a busca foi feita em uma amostra aleatória de 4.000 registros do treino, e o melhor modelo foi retreinado com todo o treino. A combinação escolhida foi **kernel rbf, $C = 10$, $\epsilon = 0,1$ e $\gamma = scale$** , com R^2 médio de 0,7498 na validação cruzada.

4 RESULTADOS E DISCUSSÃO

4.1 Experimentos

Tabela 4. Experimentos realizados

Modelo	Tratamento	Kernel	C	Epsilon	R^2
Baseline	Nenhum	rbf	1	0,1	-0,0546
Modelo 2	Valores ausentes	rbf	1	0,1	-0,0487
Modelo 3	Outliers	rbf	1	0,1	-0,0481
Modelo 4	Outliers e padronização de X	rbf	1	0,1	-0,0425
Modelo 5	Outliers e padronização de X e y	rbf	1	0,1	0,7487
Modelo final	Tratados, padronização e GridSearch	rbf	10	0,1	0,7678

Os quatro primeiros modelos tiveram R^2 negativo, ou seja, foram piores do que prever a média. A padronização apenas dos atributos não resolveu, e o R^2 só saltou para 0,7487 quando o alvo também foi padronizado. Com valores na casa das centenas de milhares de dólares, o parâmetro $C = 1$ limita a amplitude do que o modelo consegue representar e ele prevê valores quase constantes. A padronização do alvo foi, com folga, o tratamento de maior impacto. A busca em grade acrescentou 0,0191 ao R^2 do Modelo 5.

O efeito do capping foi medido de novo com atributos e alvo padronizados, já que a comparação dos Modelos 2 e 3 ocorreu com R^2 negativo: o R^2 foi de 0,7474 sem capping e de 0,7487 com capping, uma diferença de 0,0013. É um efeito marginal, medido em uma única divisão treino e teste, e não permite afirmar que o capping melhora o modelo.

4.2 Comparação de kernels

Tabela 5. Desempenho por kernel (dados tratados, alvo padronizado, $C = 1$, $\epsilon = 0,1$)

Kernel	R^2
linear	0,6147
rbf	0,7487
poly	0,6814

O *rbf* foi o melhor. O kernel *linear* já chega perto de 0,65 porque a renda mediana tem relação quase linear com o preço, mas só o *rbf* representa bem o efeito não linear da localização.

4.3 Desempenho final


Tabela 6. Desempenho do modelo final no conjunto de teste

Métrica	Valor
R^2	0,7678
MAE	US\$ 36.422,83
RMSE	US\$ 55.155,71
MAE em relação ao valor médio das casas	17,6%

O modelo final atingiu **R^2 de 0,7678** no conjunto de teste, acima do mínimo de 0,65, explicando cerca de 77% da variabilidade do valor das casas. O RMSE é bem maior que o MAE, o que indica erros grandes concentrados em parte dos registros. Uma ressalva: as comparações de tratamentos e de kernels foram medidas no próprio conjunto de teste, de modo que o R^2 final pode estar um pouco otimista. A busca em grade, que escolheu os hiperparâmetros, usou apenas dados de treino.

4.4 Valores reais e valores previstos

Figura 1. Valores reais e valores previstos no conjunto de teste



Os pontos acompanham a diagonal até cerca de 300 mil dólares, com dispersão crescente nas faixas mais altas. A coluna vertical em 500 mil dólares é o teto da base: nesses registros o valor real está limitado e o modelo tende a subestimar. Há também pontos isolados longe da diagonal e uma previsão levemente negativa, que não faz sentido para um preço. O MAE

equivale a 17,6% do valor médio das casas, o que serve para estimativas gerais, mas não para avaliar um imóvel individual.

5 CONCLUSÃO

1. O modelo atingiu $R^2 > 0,65$? Sim. O R^2 no conjunto de teste foi de 0,7678, com MAE de US\$ 36.422,83 e RMSE de US\$ 55.155,71.

2. Qual tratamento teve maior impacto? A padronização da variável alvo. O R^2 passou de -0,0425 para 0,7487 quando o alvo também foi padronizado. Na classificação, o alvo é uma classe e não precisa ser reescalado, mas na regressão o alvo é contínuo e sua escala interfere diretamente nos parâmetros do SVR.

3. O tratamento dos outliers melhorou o resultado? De forma marginal: R^2 de 0,7474 sem capping e de 0,7487 com capping, diferença de 0,0013. Mantive o capping porque não custa registros, mas o desempenho se deve à padronização do alvo. O mesmo vale para os valores ausentes, cujas estratégias ficaram entre 0,7459 e 0,7550.

4. Qual kernel foi melhor? O *rbf*, com 0,7487, contra 0,6814 do *poly* e 0,6147 do *linear*, coerente com a relação não linear entre localização e valor das casas.

5. Quais hiperparâmetros foram usados no modelo final? Kernel *rbf*, $C = 10$, $\epsilon = 0,1$ e $\gamma = scale$, com atributos e alvo padronizados.

6. Quais dificuldades foram encontradas? O R^2 negativo inicial, cuja causa era a escala do alvo e não um erro de código; o custo computacional do SVR, que levou a executar a busca em grade em uma amostra de 4.000 registros; e o teto de 500.001 no alvo. Como limitações de método, a imputação e o capping foram calculados com a base completa antes da divisão, e as comparações foram feitas no conjunto de teste.

7. O modelo poderia ser melhorado? Sim: calcular imputação e capping apenas no treino, dentro de um *pipeline*; aplicar transformação logarítmica ao alvo; criar atributos como cômodos por domicílio; tratar à parte os registros do teto de 500.001; rodar a busca em grade com todo o treino e faixas maiores de C e γ ; e limitar as previsões a valores positivos.